Seveyrat Camille L2 MIASHS

22303443 2024/2025

Science des données 1

Classification supervisée et non supervisée pour l'analyse de d'images et de données textuelles

Enseignante : Nefissa Khiari

Dans ce rapport, j'ai exploré deux méthodes d'apprentissage automatique : premièrement, une approche non supervisée appliquée à des données d'images pour le regroupement d'ordures, et deuxièmement, une approche supervisée appliquée à des données textuelles pour la classification de titres d'articles d'actualité.

Pour ces deux types d'apprentissage, j'ai commencé par détailler le contenu des données originales, puis j'ai pu décrire le processus suivi pour constituer mon jeu de données et le rendre exploitable. J'ai ensuite présenté la chaîne de traitement mise en place avec le logiciel Orange, suivi des résultats obtenus et de leur interprétation. Lors de cette interprétation, j'ai cherché à expliquer la raison de la qualité des résultats, qu'ils soient conformes à mes attentes ou non.

Table des matières

1 - Apprentissage non supervisé

1.1 - Jeu de données

Description du jeu de données ainsi que du processus suivi pour le constituer.

1.2 - Chaîne de traitement

Description de la chaîne mise en place :

- *démarche adoptée pour prétraiter les données.*
- *description des différents outils nécessaire à la réalisation du clustering.*
- *aperçu des résultats.*

1.3 - Interprétation

Interprétation des résultats obtenus.

2 - Apprentissage supervisé

2.1 - Jeu de données

Description du jeu de données ainsi que du processus suivi pour le constituer.

2.2 - Chaîne de traitement

Description de la chaîne mise en place :

- *démarche adoptée pour prétraiter les données.*
- *description des outils nécessaires à la classification.*
- *comparaison des modèles de classification.*
- *aperçu des résultats.*

2.3 - Interprétation

Interprétation des résultats obtenus.

2.4 – Visualisation des données

Présentation d'un tableau de bord et analyse.

3 – Conclusion

1 - Apprentissage non supervisé

1.1 – Jeu de données

Pour l'algorithme d'apprentissage non supervisé, j'ai choisi d'utiliser un jeu de données composé d'images portant sur la classification des ordures. Le jeu de données original, trouvé sur le site web Kaggle (« *Garbage Classification (12 classes)* »), comprend 12 classes différentes, représentant divers types de déchets. Cependant, pour simplifier l'analyse, j'ai restreint l'étude à seulement 5 classes parmi les 12 disponibles.

Voici les 5 classes retenues :

- Les piles (*battery*)
- Les déchets biologiques (*biological*)
- Le carton (*cardboard*)
- Le verre vert (*green-glass*)
- Le métal (*metal*)

Pour chacune de ces classes, j'ai sélectionné 15 images présentant des caractéristiques communes plus ou moins visibles, puis ces 75 images au total ont été placées dans un seul et même dossier. Il peut être intéressant d'observer si un algorithme non supervisé, qui se base seulement sur les propriétés visuelles directement présentes dans les images, pourrait parvenir à trier et regrouper correctement les déchets.

1.2 – Chaîne de traitement

Pour pouvoir réaliser un clustering hiérarchique portant sur des ressemblances visuelles entre images, j'ai d'abord dû « transformer » ces images en vecteurs de nombres grâce à l'outil *Image Embedding*.

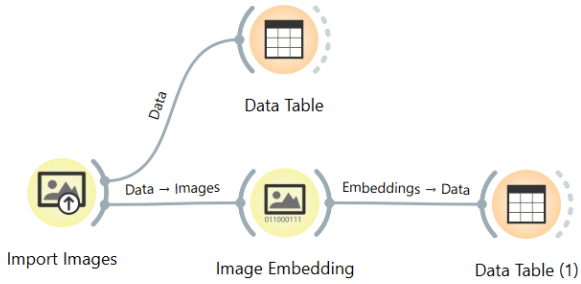

Début de chaîne de traitement – apprentissage non supervisé

En sortie de *Image Embedding*, j'ai tout d'abord ajouté l'outil *Data Table* qui m'a permis d'observer les calculs effectués précédemment : au total, on obtient 512 caractéristiques avec une valeur pour chaque image.

Les images étant maintenant représentées par des données numériques, il est donc possible de les comparer en calculant la distance entre les vecteurs de caractéristiques de chaque image.

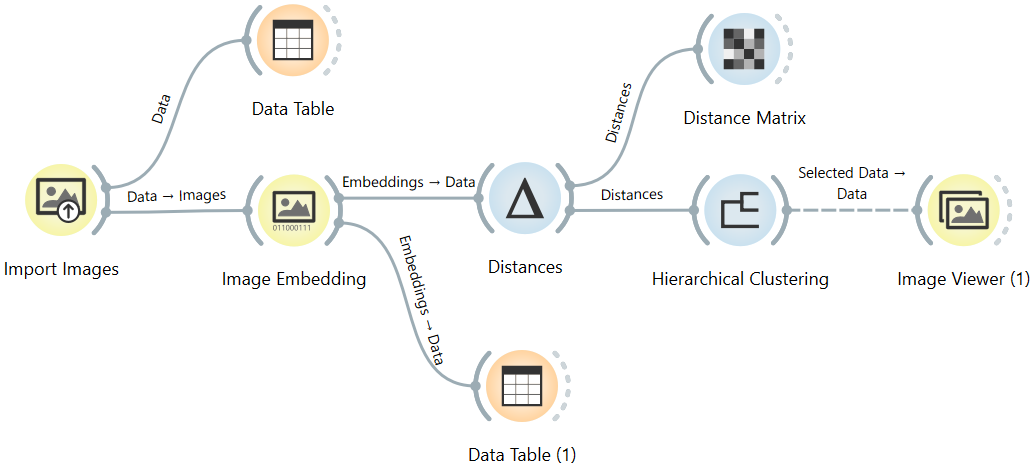

Chaîne de traitement pour l'apprentissage non supervisé

Avec l'outil *Distances*, j'ai tout d'abord choisi la distance cosinus.

Avant d'observer le dendrogramme obtenu, il est intéressant de visualiser les écarts numériques entre les images avec l'outil *Distance Matrix*. Avec une simple observation, j'ai pu constater quelques résultats saillants.

Distance Matrix - Orange

File View Window Help

	battery1	battery10	battery11	battery12	battery13	battery14	battery15	battery2	battery3	battery4	battery5	battery6	battery7	battery8	battery9	biological1	biological10	biological11	biologic
battery1		0,033	0,020	0,045	0,036	0,008	0,010	0,023	0,013	0,024	0,034	0,014	0,030	0,014	0,034	0,410	0,198	0,244	0,167
battery10	0,033		0,070	0,062	0,019	0,033	0,048	0,093	0,041	0,020	0,014	0,021	0,033	0,070	0,005	0,456	0,137	0,168	0,099
battery11	0,020	0,070		0,074	0,068	0,021	0,021	0,014	0,032	0,045	0,075	0,049	0,044	0,022	0,066	0,424	0,232	0,285	0,203
battery12	0,045	0,062	0,074		0,056	0,037	0,042	0,077	0,040	0,049	0,035	0,037	0,087	0,051	0,070	0,325	0,150	0,179	0,126
battery13	0,036	0,019	0,068	0,056		0,037	0,047	0,091	0,052	0,019	0,030	0,018	0,031	0,064	0,017	0,478	0,178	0,194	0,122
battery14	0,008	0,033	0,021	0,037	0,037		0,005	0,029	0,014	0,013	0,035	0,014	0,035	0,018	0,033	0,418	0,197	0,234	0,153
battery15	0,010	0,048	0,021	0,042	0,047	0,005		0,027	0,016	0,021	0,045	0,017	0,036	0,016	0,046	0,401	0,217	0,254	0,173
battery2	0,023	0,093	0,014	0,077	0,091	0,029	0,027		0,036	0,064	0,093	0,061	0,063	0,012	0,088	0,399	0,249	0,304	0,227
battery3	0,013	0,041	0,032	0,040	0,052	0,014	0,016	0,036		0,029	0,027	0,024	0,050	0,017	0,047	0,396	0,172	0,231	0,167
battery4	0,024	0,020	0,045	0,049	0,019	0,013	0,021	0,064	0,029		0,030	0,015	0,022	0,041	0,016	0,465	0,188	0,218	0,140
battery5	0,034	0,014	0,075	0,035	0,030	0,035	0,045	0,093	0,027	0,030		0,020	0,054	0,061	0,026	0,410	0,125	0,166	0,111
battery6	0,014	0,021	0,049	0,037	0,018	0,014	0,017	0,061	0,024	0,015	0,020		0,031	0,035	0,022	0,432	0,190	0,216	0,140
battery7	0,030	0,033	0,044	0,087	0,031	0,035	0,036	0,063	0,050	0,022	0,054	0,031		0,049	0,025	0,483	0,223	0,262	0,180
battery8	0,014	0,070	0,022	0,051	0,064	0,018	0,016	0,012	0,017	0,041	0,061	0,035	0,049		0,066	0,401	0,221	0,278	0,207
battery9	0,034	0,005	0,066	0,070	0,017	0,033	0,046	0,088	0,047	0,016	0,026	0,022	0,025	0,066		0,476	0,155	0,185	0,110
biological1	0,410	0,456	0,424	0,325	0,478	0,418	0,401	0,399	0,396	0,465	0,410	0,432	0,483	0,401	0,476		0,334	0,365	0,391
biological10	0,198	0,137	0,232	0,150	0,178	0,197	0,217	0,249	0,172	0,188	0,125	0,190	0,223	0,221	0,155	0,334		0,040	0,063
biological11	0,244	0,168	0,285	0,179	0,194	0,234	0,254	0,304	0,231	0,218	0,166	0,216	0,262	0,278	0,185	0,365	0,040		0,027
biological12	0,167	0,099	0,203	0,126	0,122	0,153	0,173	0,227	0,167	0,140	0,111	0,140	0,180	0,207	0,110	0,391	0,063	0,027	
biological13	0,123	0,083	0,164	0,074	0,116	0,117	0,135	0,182	0,105	0,120	0,064	0,111	0,169	0,156	0,105	0,332	0,049	0,060	0,044
biological14	0,061	0,064	0,088	0,071	0,077	0,077	0,077	0,099	[illegible]	0,080	0,045	0,062	0,074	0,070	0,071	0,351	0,118	0,191	0,161

Labels: image name

Send Automatically

75×75

Distance Matrix (1)

On peut voir ci-dessus que les images des piles ont des distances très faibles entre elles ; les similarités entre les images ont donc bien été détectées, ce qui n'est pas le cas pour tous les groupes.

Cependant, j'ai aussi pu remarquer des résultats qui vont à l'encontre de mes attentes.

Distance Matrix - Orange

File View Window Help

	battery1	battery10	battery11	battery12	battery13	battery14	battery15	battery2	battery3	battery4	battery5	battery6	battery7	battery8	battery9	biological1	biological10	biological11	biologica
cardboard8	0,226	0,315	0,231	0,200	0,275	0,247	0,236	0,210	0,234	0,287	0,278	0,257	0,287	0,199	0,319	0,291	0,360	0,410	0,390
cardboard9	0,144	0,243	0,135	0,138	0,212	0,167	0,155	0,112	0,154	0,219	0,208	0,186	0,218	0,118	0,245	0,290	0,308	0,369	0,333
green-glass1	0,039	0,115	0,018	0,088	0,101	0,044	0,038	0,012	0,055	0,083	0,113	0,073	0,077	0,028	0,111	0,401	0,272	0,317	0,242
green-glass10	0,141	0,227	0,145	0,163	0,217	0,168	0,148	0,132	0,162	0,221	0,205	0,177	0,204	0,146	0,240	0,218	0,312	0,360	0,316
green-glass11	0,027	0,072	0,042	0,050	0,062	0,035	0,031	0,043	0,040	0,052	0,064	0,046	0,049	0,035	0,072	0,354	0,222	0,265	0,194
green-glass12	0,018	0,072	0,013	0,070	0,077	0,025	0,027	0,009	0,026	0,052	0,072	0,053	0,051	0,012	0,070	0,405	0,212	0,275	0,206
green-glass13	0,028	0,027	0,051	0,051	0,050	0,027	0,035	0,071	0,018	0,036	0,017	0,028	0,056	0,050	0,038	0,405	0,137	0,191	0,134
green-glass14	0,027	0,030	0,047	0,041	0,033	0,018	0,026	0,067	0,029	0,015	0,036	0,025	0,040	0,048	0,032	0,419	0,176	0,207	0,132
green-glass15	0,040	0,107	0,031	0,082	0,102	0,050	0,042	0,031	0,053	0,085	0,103	0,079	0,080	0,043	0,107	0,346	0,244	0,297	0,226
green-glass2	0,089	0,158	0,100	0,119	0,158	0,117	0,115	0,090	0,099	0,165	0,137	0,130	0,164	0,096	0,175	0,293	0,235	0,297	0,255
green-glass3	0,067	0,141	0,082	0,087	0,122	0,090	0,080	0,072	0,072	0,126	0,112	0,095	0,126	0,061	0,150	0,298	0,240	0,303	0,260
green-glass4	0,100	0,156	0,134	0,091	0,148	0,114	0,104	0,124	0,115	0,150	0,129	0,107	0,159	0,113	0,171	0,251	0,267	0,299	0,250
green-glass5	0,096	0,148	0,114	0,112	0,151	0,119	0,108	0,121	0,102	0,156	0,117	0,116	0,155	0,118	0,168	0,278	0,239	0,294	0,249
green-glass6	0,076	0,157	0,049	0,095	0,134	0,073	0,058	0,039	0,086	0,107	0,147	0,104	0,102	0,048	0,149	0,353	0,280	0,321	0,259
green-glass7	0,122	0,213	0,126	0,117	0,183	0,145	0,126	0,108	0,140	0,193	0,179	0,149	0,183	0,109	0,221	0,235	0,296	0,345	0,305
green-glass8	0,122	0,181	0,127	0,135	0,154	0,153	0,155	0,129	0,142	0,188	0,159	0,154	0,177	0,131	0,195	0,345	0,257	0,313	0,271
green-glass9	0,031	0,091	0,025	0,042	0,077	0,027	0,020	0,025	0,037	0,054	0,078	0,051	0,065	0,021	0,089	0,352	0,223	0,269	0,200
metal1	0,194	0,243	0,232	0,169	0,231	0,211	0,196	0,218	0,206	0,239	0,212	0,196	0,245	0,206	0,256	0,232	0,323	0,339	0,305
metal10	0,017	0,035	0,049	0,033	0,036	0,018	0,020	0,061	0,018	0,029	0,023	0,012	0,055	0,039	0,042	0,406	0,192	0,226	0,152
metal11	0,399	0,394	0,420	0,368	0,429	0,397	0,406	0,429	0,378	0,418	0,376	0,415	0,460	0,430	0,425	0,384	0,379	0,385	0,374
metal12	0,107	0,161	0,140	0,103	0,158	0,129	0,117	0,132	[illegible]	0,167	0,127	0,119	0,175	0,121	0,182	0,218	0,242	0,282	0,243

Labels: image name

Send Automatically

75×75

Distance Matrix (2)

Ici par exemple, on peut clairement observer que l'algorithme a trouvé des similarités entre les piles et le verre vert. Ce résultat est assez imprévu, mais je pourrai tenter de l'interpréter par la suite.

Après un aperçu global des distances, on peut s'intéresser au clustering hiérarchique que l'on obtient.

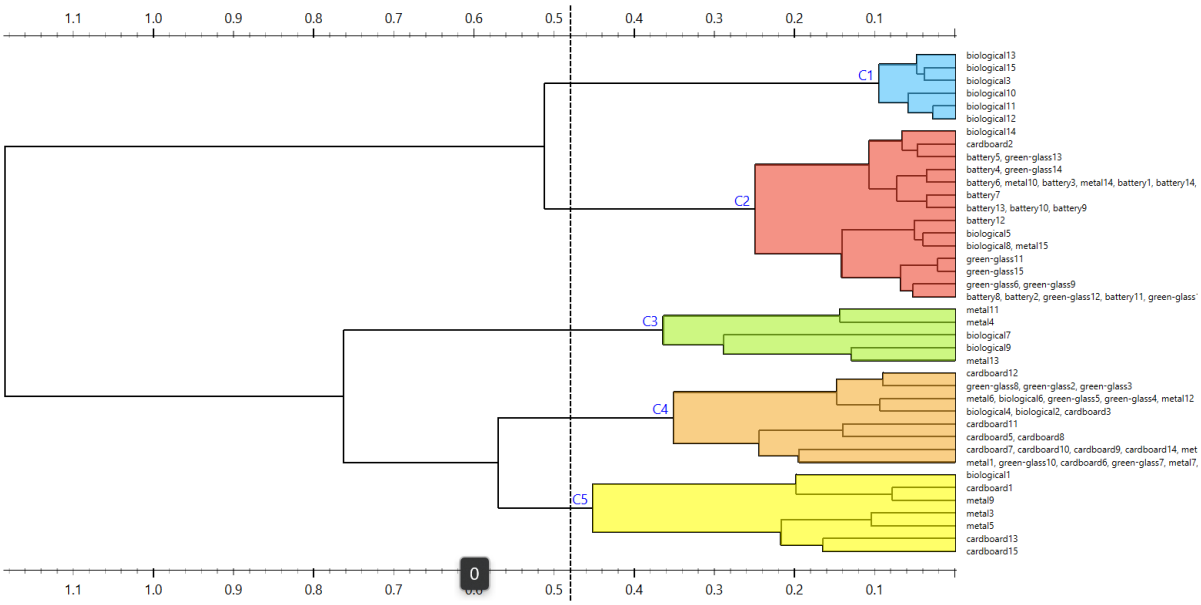

Clustering hiérarchique des 5 types de déchets

En sachant qu'il y a 5 types de déchets différents à trier, j'ai placé la ligne de coupe de sorte à avoir 5 clusters. On peut voir que ces 5 clusters ont des tailles inégales et que les groupes formés sont inexacts compte tenu de mes attentes, mais on peut s'y intéresser de plus près :

Tout d'abord, on peut noter que l'algorithme a su regrouper 6 images de déchets biologiques dans le cluster C1. Les 9 autres images de déchets biologiques se retrouvent dispersées dans les quatre autres clusters.

Ensuite, le cluster C2 lui regroupe au total 30 images, dont les 15 images des piles qui sont donc toutes dans ce cluster. On y retrouve également 8 images de déchets en verre vert, ce qui est en accord avec les observations précédentes de la matrice de distances. Mais on y constate également la présence d'images provenant des trois autres groupes de déchets.

Après cela, le cluster C3 ne comprends que 5 images : deux images de déchets biologiques et 3 autres de déchets métalliques.

Par la suite, le cluster 4 regroupe lui 27 images, principalement du carton avec 11 images, mais aussi avec des déchets biologiques, du verre vert et du métal.

Pour finir, le cluster C5 contient 7 images : une image de déchet biologique, 3 images de cartons et 3 autres de métal.

On peut constater que parmi ces 5 clusters, 2 d'entre eux cumulent environ les trois quarts du nombre total d'images fournies.

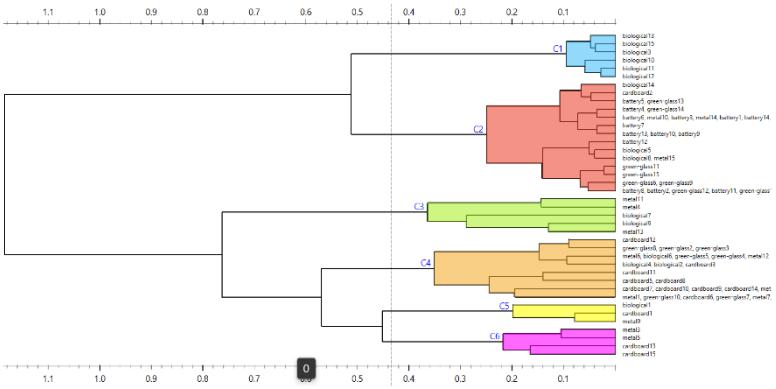

Cependant, si l'on essaie de déplacer la ligne de coupe de sorte à avoir 6 clusters, on obtient de moins bons résultats encore. C'est le cluster C5 de départ qui se retrouve divisé en deux alors qu'il compte seulement 7 images.

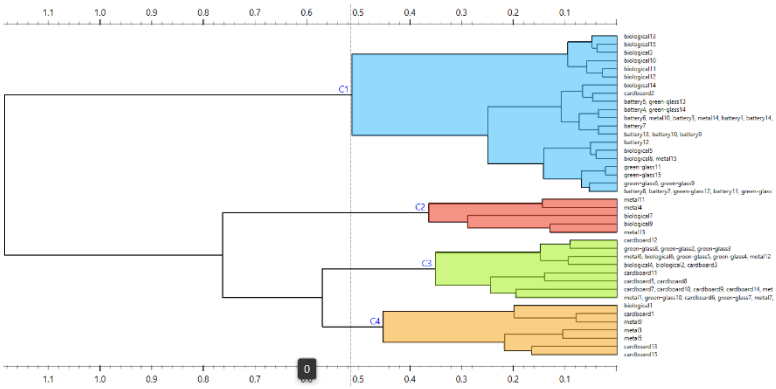

Et si au contraire, on essaie de déplacer la ligne de coupe de sorte à avoir 4 clusters, ce sont les clusters C1 et C2 qui se retrouvent regroupés : cela donne donc un cluster à 36 images et les images des 6 déchets biologiques qui étaient bien regroupés se retrouvent mélangés aux autres.

1.3 – Interprétation

De par nos résultats obtenus, on peut dire que l'algorithme n'a pas bien su regrouper les images de déchets fournis. Mais on a également pu voir que certains clusters semblaient

avoir été assez bien triés en partie. On a pu observer que le premier cluster n'était formé que de déchets biologiques, et voici les images qu'il contient :

Contenu du cluster C1

Visuellement, on peut faire des liens entre ces images : le nombre de fruits est important et les couleurs sont vives, ce qui n'est pas le cas pour toutes les images de déchets biologiques.

Déchets biologiques dans le cluster C4

Ces trois autres images de déchets biologiques ont été placées dans le cluster C4. On constate que ces déchets se distinguent visuellement de ceux des images précédentes, ce qui peut donc expliquer ce regroupement.

Ensuite, on avait pu voir aussi que les images de verre vert et les images des piles avaient des vecteurs de caractéristiques très proches ; on peut donc se demander pourquoi.

Contenu du cluster C2

Voici ci-dessus le cluster C2, qui regroupe 30 images dont les 15 images des piles. On peut constater quelques ressemblances entre ces images : elles ont toutes un fond clair et on retrouve dans la plupart de ces images des formes cylindriques. Ces deux critères peuvent

donc être à l'origine de la proximité des vecteurs de caractéristiques de ces images-ci et donc des piles et du verre vert.

Cependant, certains résultats peuvent se révéler être plus compliqués à interpréter. On a notamment le cluster C3 :

Cluster C3

Il est ici difficile d'interpréter ce groupement d'images et de trouver une caractéristique commune entre elles car elles ont visuellement peu de ressemblances notables.

J'ai pu observer que l'algorithme, bien qu'il identifie des groupements approximativement cohérents avec mes attentes, se base uniquement sur des similitudes visuelles entre les données. N'ayant pas de connaissances préalables ou d'étiquettes pour guider son regroupement, il produit parfois des résultats qui divergent de mes attentes.

2 – Apprentissage supervisé

2.1 – Jeu de données

Pour l'apprentissage supervisé, j'ai choisi un jeu de données textuelles ici aussi sur le site web Kaggle (« *News Aggregator Dataset* »). Le jeu de données original contient les titres, les URL et les catégories de plusieurs milliers d'articles d'actualité.

Les catégories des articles sont les suivantes :

- B : Affaires (*Business*)
- T : Science et technologie (*Science and technology*)
- E : Divertissement (*entertainment*)
- M : Santé (*health*)

Pour constituer mon jeu de données, j'ai donc sélectionné les titres de 25 articles de chaque catégorie pour la phase d'entraînement du modèle, puis 5 autres titres d'articles de chaque catégorie également pour la phase de test. J'ai voulu évaluer les performances du modèle supervisé dans la classification de titres d'actualité, en lui fournissant des connaissances préalables sur chaque catégorie.

2.2 – Chaîne de traitement

Étant donné la nature textuelle des données, une phase de prétraitement est nécessaire afin d'optimiser la qualité de l'entraînement.

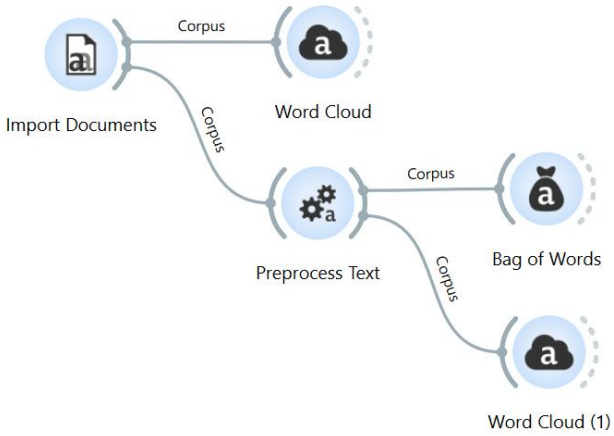

Début de chaîne de traitement – apprentissage non supervisé

En premier lieu, grâce à un premier outil *Word Cloud*, j'ai pu visualiser les caractères, les mots et la ponctuation les plus fréquents dans les données. Comme la ponctuation et les mots d'arrêt n'étaient pas pertinents pour l'entraînement et risquaient de provoquer des erreurs de classification par la suite, j'ai donc utilisé l'outil *Preprocess Text* pour les supprimer. A l'aide des réglages, les signes de ponctuation ont été supprimés ainsi que les mots d'arrêt, mais j'ai également ajouté un fichier *stopwords* pour supprimer les mots « a », « être » et « plus » du nuage de mots en sortie de *Preprocess Text*.

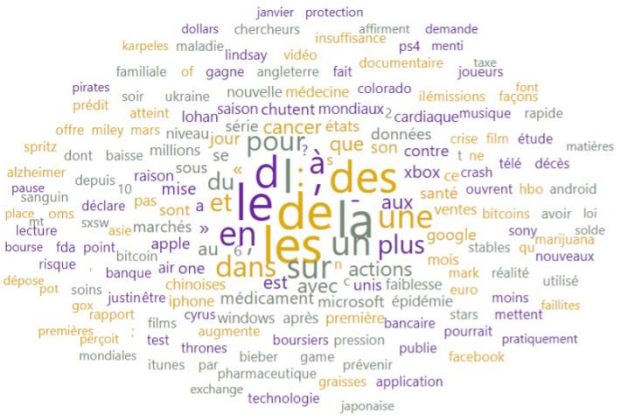

Word Cloud avant Preprocess Text

Word Cloud après Preprocess Text

Pour finir, j'ai utilisé l'outil *Bag of Words* pour transformer mes données en une représentation numérique afin qu'elles puissent être traitées.

Une fois la phase de prétraitement terminée, j'ai pu passer à l'entraînement des modèles.

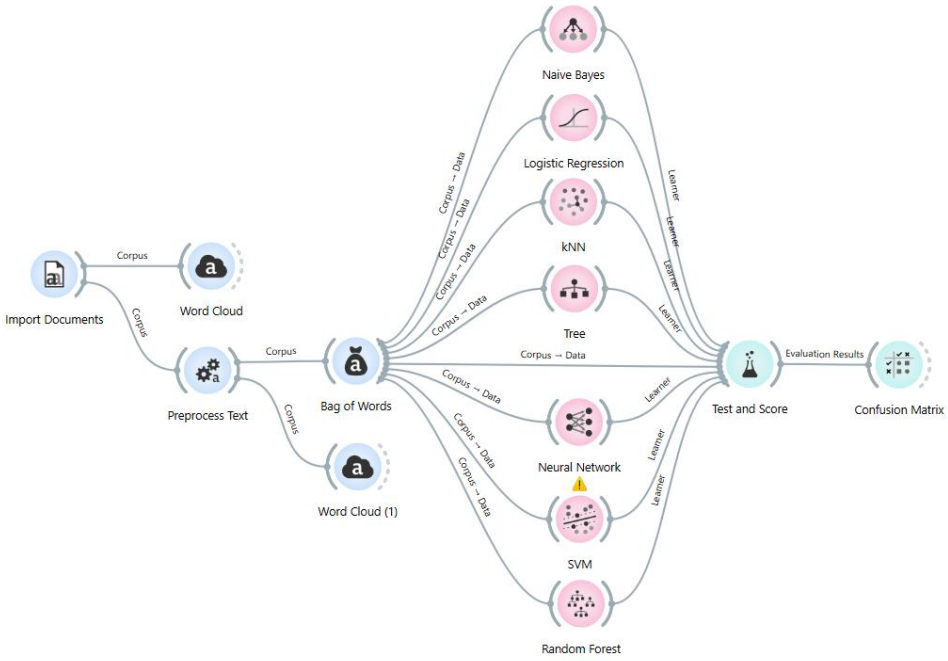

Chaîne de traitement pour l'apprentissage non supervisé – phase d'entraînement

Tous les modèles prennent ici en entrée *Bag of Words* et en sortie l'outil *Test and Score*, qui permet d'évaluer la performance des modèles grâce à des mesures de performance, présentes ci-dessous.

Model	AUC	CA	F1	Prec	Recall	MCC
Neural Network	0.934	0.690	0.687	0.709	0.690	0.593
Logistic Regression	0.931	0.770	0.764	0.802	0.770	0.706
Naive Bayes	0.909	0.700	0.698	0.737	0.700	0.612
kNN	0.741	0.410	0.359	0.635	0.410	0.244
Random Forest	0.731	0.520	0.516	0.632	0.520	0.377
Tree	0.706	0.460	0.469	0.649	0.460	0.302
SVM	0.299	0.350	0.341	0.542	0.350	0.145

Test and Score – Mesures de performance des modèles

On y voit des valeurs d'exactitude aussi appelée accuracy (**CA**), de rappel (**recall**), de précision (**prec**) et de F1-score (**F1**). On y voit aussi les mesures **ROC** et **AUC** qui évaluent la qualité d'un modèle dans les classifications binaires.

En comparant les valeurs de chaque modèle, on constate rapidement que *Logistic Regression* semble être le meilleur modèle, mais il est suivi de près par *Neural Network* et *Naive Bayes*.

J'ai ensuite comparé la matrice de confusion de ces trois modèles pour pouvoir faire le meilleur choix.

Actual \ Predicted	B - AFFAIRES	T - SCIENCE ET TECHNOLOGIE	M - SANTE	E - DIVERTISSEMENT	Σ
B - AFFAIRES	13	2	3	7	25
T - SCIENCE ET TECHNOLOGIE	1	19	1	4	25
M - SANTE	0	2	21	2	25
E - DIVERTISSEMENT	0	1	0	24	25
Σ	14	24	25	37	100

Logistic Regression – Matrice de confusion

Actual \ Predicted	B - AFFAIRES	T - SCIENCE ET TECHNOLOGIE	M - SANTE	E - DIVERTISSEMENT	Σ
B - AFFAIRES	11	5	1	8	25
T - SCIENCE ET TECHNOLOGIE	1	18	0	6	25
M - SANTE	2	1	20	2	25
E - DIVERTISSEMENT	0	4	0	21	25
Σ	14	28	21	37	100

Naive Bayes – Matrice de confusion

Actual \ Predicted	B - AFFAIRES	T - SCIENCE ET TECHNOLOGIE	M - SANTE	E - DIVERTISSEMENT	Σ
B - AFFAIRES	13	6	4	2	25
T - SCIENCE ET TECHNOLOGIE	2	19	3	1	25
M - SANTE	2	2	21	0	25
E - DIVERTISSEMENT	1	5	3	16	25
Σ	18	32	31	19	100

Neural Network – Matrice de confusion

Comme prédit précédemment, le modèle *Logistic Regression* se révèle être le meilleur. En additionnant les nombres dans la diagonale principale, on peut dire qu'il a réussi à classer correctement 77 titres d'articles sur 100, contre 70 pour *Naive Bayes* et 69 pour *Neural Network*.

La phase d'entraînement étant terminée, j'ai pu passer à la phase de test avec au total 20 titres d'articles à classer, soit 5 titres par classe.

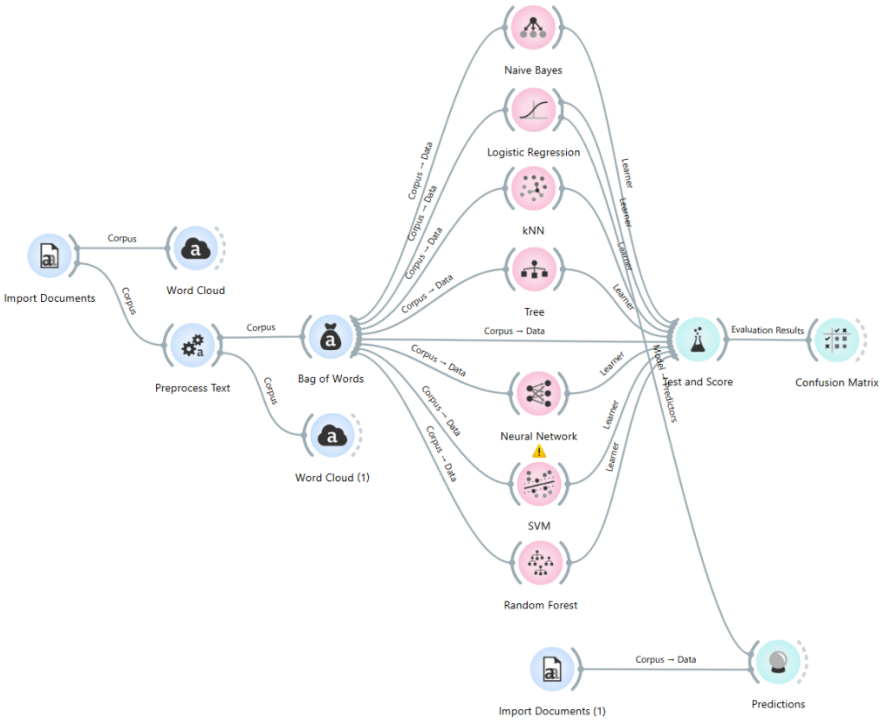

Chaîne de traitement pour l'apprentissage non supervisé

L'image ci-dessus illustre l'ensemble des phases nécessaires à la réalisation de prédictions. Pour la phase de test, j'ai ajouté l'outil *Predictions*, avec en entrée *Import*

Documents où j'ai importé les titres d'articles non triés, mais aussi le modèle *Logistic Regression* préalablement entraîné, que j'ai choisi en raison de ses bonnes performances.

On peut donc s'intéresser aux résultats des prédictions :

	Logistic Regression	name	path	content
1	B - AFFAIRES	TESTB1	C:/Documents/...	Des pirates acc...
2	B - AFFAIRES	TESTB2	C:/Documents/...	La politique mo...
3	B - AFFAIRES	TESTB3	C:/Documents/...	APERÇU DU M...
4	E - DIVERTISSEMENT	TESTB4	C:/Documents/...	L'UE vise un acc...
5	B - AFFAIRES	TESTB5	C:/Documents/...	Selon M. Noyer,...
6	E - DIVERTISSEMENT	TESTE1	C:/Documents/...	Justin Bieber dé...
7	E - DIVERTISSEMENT	TESTE2	C:/Documents/...	La télé-réalité d...
8	E - DIVERTISSEMENT	TESTE3	C:/Documents/...	Le chef de la tél...
9	E - DIVERTISSEMENT	TESTE4	C:/Documents/...	Audiences télév...
10	E - DIVERTISSEMENT	TESTE5	C:/Documents/...	Ce groupe a jo...
11	M - SANTE	TESTM1	C:/Documents/...	Taux de cancer l...
12	M - SANTE	TESTM2	C:/Documents/...	Le diabète gest...
13	M - SANTE	TESTM3	C:/Documents/...	Stratégies de sa...
14	M - SANTE	TESTM4	C:/Documents/...	Le trouble de st...
15	M - SANTE	TESTM5	C:/Documents/...	Étude : Le rôle ...
16	T - SCIENCE ET TECHNOLOGIE	TESTT1	C:/Documents/...	La résolution X...
17	T - SCIENCE ET TECHNOLOGIE	TESTT2	C:/Documents/...	Microsoft Offic...
18	T - SCIENCE ET TECHNOLOGIE	TESTT3	C:/Documents/...	Un créateur du ...
19	T - SCIENCE ET TECHNOLOGIE	TESTT4	C:/Documents/...	Google facilite l...
20	T - SCIENCE ET TECHNOLOGIE	TESTT5	C:/Documents/...	La mise à jour i...

Prédictions

Le nom des fichiers est composé du mot TEST suivi de la lettre correspondant à sa classe (*B*, *E*, *M* ou *T*) puis de son numéro.

On peut donc voir une seule erreur dans ces prédictions, à savoir à la ligne 4. Un titre a été classé par le modèle en *Divertissement* alors qu'il appartenait en réalité à la catégorie *Affaires*.

2.3 – Interprétation

Les prédictions obtenues sont globalement conformes à mes attentes, ce qui reflète la qualité de l'entraînement du modèle.

Les titres d'articles d'actualités ont en effet généralement pour objectif de rassembler les informations et les mots importants de manière concise et explicite. Ce format a très sûrement grandement contribué à la qualité des prédictions.

Word Cloud après Preprocess Text

En effet, si l'on s'intéresse de plus près au nuage de mot obtenu après la phase de prétraitement, on peut voir que les mots sont facilement associables à une catégorie. Par exemple « cancer » est associé à la santé, « google » à la technologie, « marchés » aux affaires et « saison » au divertissement.

Cependant il est possible que certains mots aient des doubles sens, comme par exemple le mot « actions » qui peut être associé à la finance ou bien au fait d'agir : ce genre de mot peut donc être à l'origine de complications pour le modèle.

De plus, compte tenu de la nature de mes données, qui sont des titres, il est possible que leur format et leur structure se ressemblent malgré les différences de catégorie. En effet, les titres, ayant pour but d'attirer l'attention, suivent souvent des structures similaires ou utilisent des expressions accrocheuses. Cette ressemblance peut entraîner des confusions pour le modèle et provoquer des erreurs de classification.

L'erreur de classification que l'on a constaté précédemment à la ligne 4 dans le tableau de prédiction, peut donc être due à une confusion dans la structure grammaticale ou bien dans une mauvaise interprétation du sens d'un mot. Mais on peut également se poser la question de la qualité de l'entraînement du modèle. Un nombre plus élevé de données d'entraînement aurait peut-être contribué à de parfaites prédictions, les évènements d'actualité pouvant être très différents au sein d'une même catégorie.

2.4 – Visualisation des données

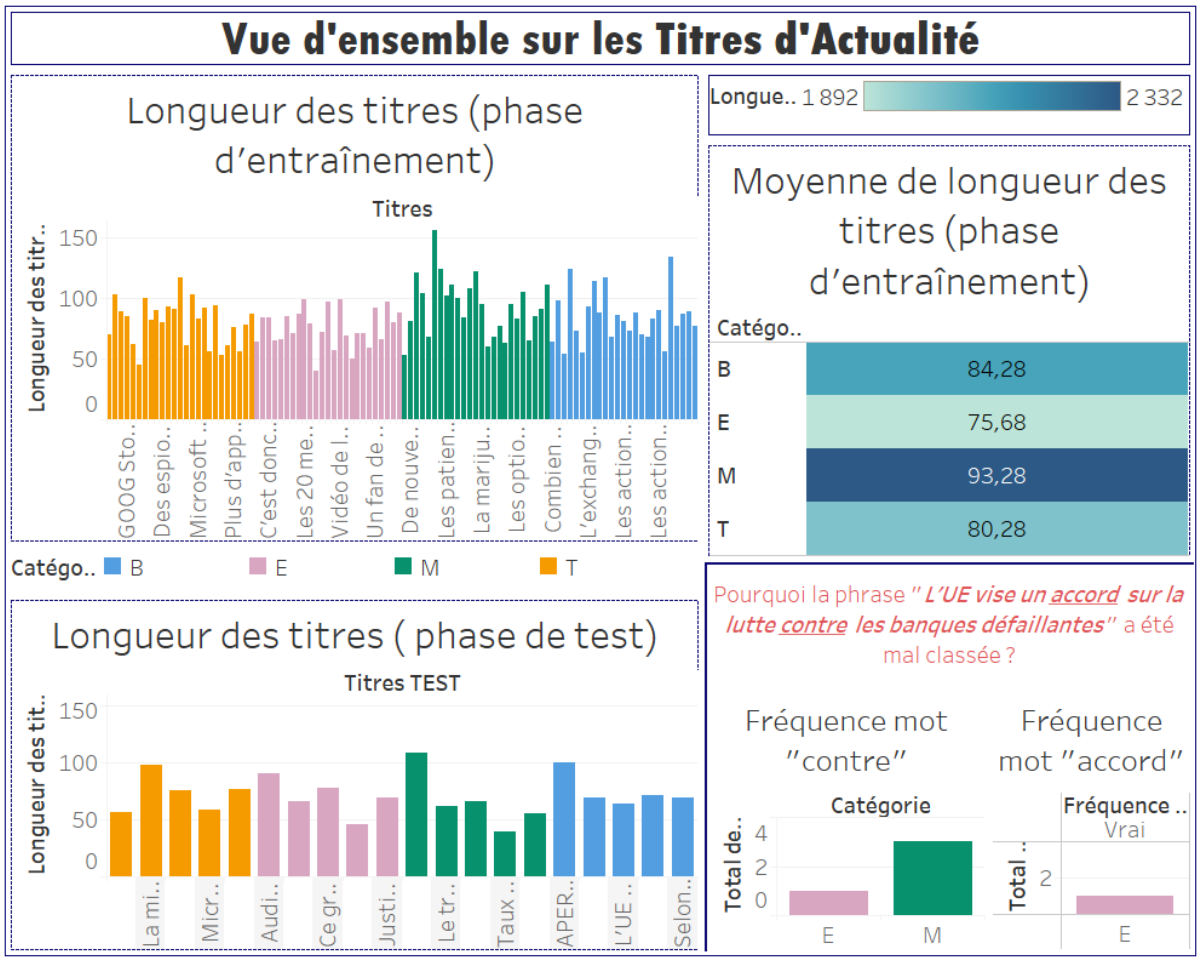

Tableau de bord réalisé avec le logiciel Tableau

L'utilisation du logiciel Tableau m'a permis d'explorer des aspects que je n'avais pas pu analyser avec le logiciel Orange. Par exemple, j'ai étudié la longueur des titres en caractères et comparé, à l'aide de deux graphiques en barres, la longueur des titres par catégorie. J'ai observé une différence notable entre les longueurs des titres d'entraînement et de test. En particulier, les titres utilisés pour la phase de test de l'apprentissage supervisé sont souvent plus courts et dépassent très rarement les moyennes de longueur des titres destinés à la phase d'entraînement. D'un côté, cela peut être un avantage, car des titres plus concis réduisent le risque de confusion pour le modèle. Mais d'un autre, cette brièveté peut entraîner un manque d'informations utiles à la classification.

Par ailleurs, je me suis intéressée à la phrase pour laquelle le modèle a commis une erreur de classification. En analysant les occurrences des mots dans cette phrase, j'ai remarqué que deux mots, « *accord* » et « *contre* », figuraient également dans les données d'entraînement. Toutefois, ces mots n'étaient présents que dans les catégories « *Divertissement* » et « *Santé* », et non dans la catégorie d'origine de la phrase, « *Affaires* ».

Grâce aux résultats obtenus, on peut dire que cela a vraisemblablement contribué à l'erreur de classification.

3 – Conclusion

Au cours de ce projet, j'ai pu analyser les deux types d'apprentissage, supervisé et non supervisé avec deux jeux de données différents.

Premièrement, en ce qui concerne l'apprentissage non supervisé, j'ai pu voir que le clustering hiérarchique obtenu n'était pas en accord avec mes attentes, à savoir le regroupement des images de déchets en fonction de leur catégorie. Si pour nous, la perception de ressemblances entre des déchets d'une même catégorie peut nous sembler évidente, il est en réalité nécessaire d'avoir des connaissances visuelles sur le sujet pour parvenir à bien les trier. Les éléments importants des images qui nous, nous permettent de faire des déductions quant à la catégorie des déchets, n'ont pas été perçus comme une caractéristique importante en comparaison avec toutes les autres caractéristiques existantes dans ces images. On peut dire que l'apprentissage non supervisé, dans ce cas précis, n'a pas été efficace pour trier les images de déchets en fonction de leur catégorie.

Deuxièmement, pour l'apprentissage supervisé, j'ai pu constater que les prédictions du modèle ont été globalement satisfaisantes. Les informations fournies lors de l'entraînement du modèle sur les différentes catégories de titres d'articles se sont avérées pertinentes, contribuant à une réussite presque parfaite dans la tâche de classification. Une seule prédiction s'est révélée être incorrecte, probablement causée par une mauvaise interprétation de la phrase ou de mots en particuliers. Globalement, le modèle utilisé pour cet apprentissage supervisé s'est montré performant dans la réalisation des prédictions à partir des données fournies.